



Universidad Europea

UNIVERSIDAD EUROPEA DE MADRID

Big Data III

Geolumica: Reporte de UX/UI



GEOLUMICA
CITIES FUTURE

Integrantes:

Martin Eduardo Otero Di Lorenzo

Iker Arredondo Molina

Fernando Sánchez

Introducción

El diseño de la experiencia de usuario y la interfaz (UX/UI) de GeoLumica se ha pensado con el objetivo central de transformar un volumen masivo de datos geoespaciales y socioeconómicos en inteligencia territorial accionable. El proyecto asume como objetivo y resultado clave la capacidad de anticipar y visualizar el riesgo de declive o despoblación en áreas rurales, logrando clasificar a la totalidad de los municipios españoles. Para que esta profunda complejidad algorítmica y datos resulte intuitiva para diferentes perfiles de usuario, nuestro equipo ha estructurado la plataforma mediante una estrategia de visualización dividida.

Por ende, este reporte se divide en la explicación detallada de dos cuadros de mando independientes pero complementarios, una “vista territorial” de enfoque analítico y operativo centrado en el diagnóstico del presente y el histórico, y un panel predictivo de enfoque estratégico orientado a la toma de decisiones a futuro.

Antes de desglosar los elementos visuales de cada cuadro de mando, resulta imprescindible definir la arquitectura de datos y cómo las interfaces interactúan con ella mediante consultas/queries. Dependiendo del tipo de visualización y del modelo algorítmico, los dashboards acceden a la información a través de diferentes etapas de refinamiento dentro de nuestra base de datos.

Para alimentar el primer cuadro de mando, el sistema lanza consultas dinámicas contra la Capa Silver, la cual está estructurada mediante un modelo relacional en estrella. Al tener una tabla central de dimensiones conectada a múltiples tablas de hechos, como la luminosidad, migración, pib, entre otras, el dashboard puede ejecutar consultas SQL de agregación y uniones (Joins) de forma muy ágil. Esto permite que, cuando el usuario interactúa con la interfaz para filtrar por una provincia o municipio específico, el sistema calcule rápidamente los cambios históricos y los promedios sin comprometer el rendimiento. También esto ayuda a que se mantenga el mayor porcentaje de datos, ya que a la hora de unir se tendría que filtrar por una granularidad mayor, como anual o mensual, lo que haría que se perdiese esa capacidad de Big Data.

Por otro lado, el segundo cuadro de mando, el enfocado al machine learning y a la predicción, accede directamente a la Capa Gold. En esta capa, los datos ya han abandonado el modelo en estrella para consolidarse en un Dataframe Maestro aplanado y desnormalizado. Con esto se podrá procesar y calcular los distintos modelos de machine learning como son las predicciones de variables o los clusters.

Vision General de Arquitectura




Ilustración 1-Diagrama General de los bloques del Pipeline y su flujo de Información

Componentes principales

Para que el flujo de datos funcione de manera orquestada, hemos estructurado el sistema en seis componentes funcionales clave:

- Módulo de Extracción e Ingesta: Conjunto de procesos automáticos encargados de conectarse a fuentes externas, descargar los datos brutos (imágenes y archivos planos) y validarlos de forma preliminar antes de su almacenamiento.
- Data Lake (Capa de Almacenamiento en Bruto): Repositorio distribuido y tolerante a fallos donde conservo el histórico inmutable de toda la información extraída (Capa Bronze).
- Motor de Procesamiento y Transformación: El núcleo computacional del sistema. Se encarga de absorber los datos del Data Lake, limpiarlos, normalizarlos (Capa Silver) y ejecutar los cruces masivos de información para crear la matriz de características (Capa Gold).
- Data Warehouse (Capa de Explotación): Base de datos relacional estructurada para ofrecer tiempos de respuesta ultrarrápidos. Actúa como el puente entre los datos procesados y las herramientas de visualización de los usuarios finales.
- Módulo de Inteligencia Artificial (Machine Learning): Entorno que consume la matriz maestra (Capa Gold) para entrenar modelos de predicciones demográficas.
- Capa de Consumo y Visualización: Interfaz final del sistema, dividida en herramientas de Business Intelligence para análisis profundo y una aplicación web interactiva para hacer la información accesible y navegable mediante mapas.

Tecnologías usadas

Hemos seleccionado las siguientes herramientas y tecnologías para construir cada uno de los componentes mencionados, priorizando el rendimiento, la escalabilidad y la compatibilidad en un entorno Big Data:

- Fuentes Geoespaciales con Google Earth Engine (GEE): Para la consulta, procesamiento inicial y descarga eficiente de las imágenes satelitales complejas sin consumir recursos y espacios de nuestro data lake.
- Ingesta y Orquestación con Python: Lenguaje principal utilizado para los scripts de extracción, automatización de descargas y limpieza preliminar (librerías como Pandas, Requests y GeoPandas).
 - Docker: Para la contenerización de los entornos de ejecución, garantizando que los scripts funcionen de manera idéntica en cualquier servidor, eliminando problemas de dependencias. (Esto para ejecución en local).
- Almacenamiento Distribuido y Procesamiento (Big Data):
 - HDFS (Hadoop Distributed File System): Utilizado como Data Lake para almacenar de forma segura los grandes volúmenes de datos históricos en crudo.
 - Apache Spark (PySpark): Empleado como motor de procesamiento distribuido. Es la herramienta clave para manejar la limpieza paralela y los joins masivos que dan lugar a las capas Silver (archivos Parquet) y Gold.
- Base de Datos y Almacenamiento Relacional:
 - MariaDB: Motor de base de datos relacional seleccionado como Data Warehouse. Almacena el Modelo Estrella final y la tabla desnormalizada listos para ser consumidos.
- Machine Learning:
 - Scikit-Learn / Spark MLlib: Librerías utilizadas para la implementación de los algoritmos de aprendizaje automático (K-Means para clustering y Random Forest para regresión predictiva).
- Visualización y Frontend:
 - Power BI: Utilizado para la creación de los cuadros de mando interactivos (Descriptivo), permitiendo a los usuarios filtrar y cruzar dimensiones socioeconómicas fácilmente.
 - React: Framework de JavaScript empleado para el desarrollo de la aplicación web interactiva (Frontend), proporcionando una experiencia de usuario fluida en la navegación por los mapas de los clústeres municipales.

APIs e integración con otros sistemas

Para garantizar que los datos procesados lleguen a las aplicaciones consumidoras de forma segura y eficiente, la arquitectura expone la información mediante las siguientes vías.

Primeramente, Power BI se conecta de forma nativa al Data Warehouse en MariaDB mediante conectores ODBC, permitiendo consultas en tiempo real sobre el Modelo Estrella sin necesidad de duplicar la información en la nube. Esto se hizo para que también se pueda acceder desde la Máquina de L.O.R.C.A. Por otra parte, La comunicación entre

la base de datos MariaDB y la aplicación web desarrollada en React se realiza a través de una API interna. Esta API expone *endpoints* específicos que sirven los datos geoespaciales y los resultados de los modelos predictivos listos para ser renderizados en los mapas interactivos del usuario.

Fuentes de Datos e Ingesta

Estrategia de Ingesta y Batch

La arquitectura del proyecto GeoLúmica se nutre de información proveniente de múltiples naturalezas para capturar tanto la realidad física como la socioeconómica del territorio español. Dado que las fuentes de origen presentan latencias distintas, variando desde actualizaciones mensuales hasta anuales, el flujo de ingesta ha sido diseñado íntegramente bajo un procesamiento por lotes o batch. La implementación de un sistema de ingesta en tiempo real (streaming) fue descartada para este ecosistema, ya que un procesamiento continuo consumiría recursos computacionales sin aportar datos más recientes a los modelos analíticos.

En cuanto a la dimensión física y ambiental, el sistema utiliza la plataforma Google Earth Engine (GEE) para acceder a las imágenes satelitales provenientes del conjunto de datos VIIRS de la NOAA. Específicamente, los procesos extraen la banda de radiancia promedio (avg_rad) para medir la intensidad lumínica nocturna de cada zona. Esta extracción se realiza con una frecuencia mensual, habiéndose consolidado una serie temporal histórica ininterrumpida desde el año 2012. Aunque la granularidad nativa de estos datos satelitales es de aproximadamente 500 metros por píxel, el proceso de ingesta transforma y agrega esta información calculando la media espacial para adaptarla estrictamente al nivel municipal.

Para modelar la infraestructura de transporte, se realizan peticiones directas a la API de OpenStreetMap (OSM) mediante Python. Este proceso captura una radiografía en tiempo real o snapshot del estado de la red al momento de la ejecución. Por un lado, se extrae la red ferroviaria completa identificando estaciones y vías; por otro, se recolecta información adicional sobre la red de carreteras y el número de vehículos para construir un índice de conectividad. Debido a que la granularidad de origen de OSM es puramente vectorial y basada en coordenadas exactas, los datos son transformados en métricas municipales.

La realidad demográfica y económica se fundamenta en los datos del Instituto Nacional de Estadística (INE), integrando información a través de su API oficial y la descarga de ficheros CSV. Este bloque abarca conjuntos de datos estructurales referentes a la renta, demografía, empresas y consumo eléctrico, los cuales poseen una frecuencia de actualización anual o mensual. La granularidad de estas fuentes es de carácter híbrido; mientras que dimensiones clave como la renta, la población, el tejido empresarial y el consumo eléctrico proyectado se extraen a un nivel puramente municipal, otras métricas requieren una agregación a nivel provincial para solventar la falta de desglose local y asegurar la robustez de los modelos posteriores.

Validaciones iniciales y control de calidad

Durante esta fase de extracción y de manera previa a su almacenamiento, los algoritmos aplican estrictos controles de calidad sobre los datos en crudo. La validación arquitectónica más crítica consiste en asegurar la integridad del catálogo geográfico, verificando de forma estricta que todas las entradas mapeen correctamente contra el padrón oficial de los 8.131 municipios de España mediante el identificador unificado. Todo registro carente de este código o que presente anomalías es marcado para su revisión. De igual forma, se ejecutan validaciones de tipado y rutinas de estandarización de cadenas de texto para mitigar discrepancias originadas por cambios recientes en la toponimia o el uso de lenguas cooficiales.

Tabla resumen de dimensiones integradas

A continuación, se sintetizan las ocho fuentes y dimensiones que alimentan el modelo estrella, destacando su temporalidad y el tipo de métricas extraídas:

<i>Fuente de Datos</i>	<i>Frecuencia</i>	<i>Dimensión</i>	<i>Ejemplo de Métrica Relevante</i>
<i>NOAA (GEE - VIIRS)</i>	Mensual	Luminosidad	avg_rad (Media de radiación nocturna por municipio)
<i>OpenStreetMap</i>	Snapshot	Estaciones (OSM)	Conteo de estaciones ferroviarias en <i>buffers</i> de 1km/5km
<i>OpenStreetMap</i>	Snapshot	Conectividad	Índice de conectividad terrestre y densidad de vehículos
<i>INE - Padrón</i>	Anual	Demografía	Población total, variaciones históricas y ratio de masculinidad
<i>INE - Atlas</i>	Anual	Económica	Renta neta media por hogar y persona
<i>INE - Movilidad</i>	Anual	Migraciones	Saldo migratorio (Atracción de población frente a éxodo)
<i>INE - DIRCE</i>	Anual	Tejido Empresarial	Densidad de empresas orientadas al transporte y logística
<i>INE / CNMC</i>	Anual	Energía	Consumo eléctrico municipal proyectado

Almacenamiento

En este apartado se describe la estrategia de persistencia y organización de los datos diseñada para el ecosistema de GeoLumica. Para gestionar eficientemente el volumen y la heterogeneidad de las fuentes, se ha implementado un Data Lake distribuido basado en HDFS (Hadoop Distributed File System), complementado en su fase final con un Data Warehouse relacional en MariaDB para la capa analítica.

El Data Lake se estructura bajo una arquitectura Medallón en tres zonas lógicas. La Zona Raw/Bronce actúa como área de aterrizaje inmutable, donde se ingieren los datos conservando los formatos originales (CSV, JSON, etc.) de las fuentes diversas previamente mencionadas. Posteriormente, los datos transitan hacia la Zona Silver (o Clean), que aloja la información estandarizada y unificada bajo el identificador geográfico municipal (LAU_ID). Finalmente, la Zona Gold contiene los datos fuertemente estructurados y agregados que alimentarán directamente los modelos de Machine Learning.

En las zonas Silver y Gold se establece Apache Parquet como formato de almacenamiento normativo. Su naturaleza columnar y sus algoritmos de compresión reducen drásticamente el espacio físico en disco y optimizan el rendimiento, permitiendo que las consultas posteriores solo carguen las columnas necesarias. Para maximizar la eficiencia del procesamiento distribuido, se ha definido una estrategia de particionado dual: un particionado temporal (por año y mes) para las métricas de alta frecuencia como la radiancia lumínica, y un particionado espacial estrictamente a nivel municipal. Por último, para garantizar la tolerancia a fallos y la protección de todo el registro histórico, el clúster HDFS está configurado con un factor de replicación de tres copias por bloque de datos.

Procesamiento y Transformación




Ilustración 2- Modelo Estrella y Capa gold (simplificado)

En este apartado se detalla el flujo de transformación de datos dentro de la arquitectura Medallón del proyecto GeoLumica, el cual se basa íntegramente en un modelo de procesamiento por lotes utilizando Apache Spark (PySpark) como motor de cálculo distribuido. La primera fase de transformación toma los datos inmutables de la zona Raw

y aplica rigurosos procesos de calidad, tipado y estandarización de cadenas de texto. Durante esta etapa se ejecuta una validación geográfica crítica para asegurar de forma estricta que todas las entradas mapeen correctamente contra el padrón oficial mediante el identificador unificado `lau_id`. Como resultado de este proceso de limpieza y unión distribuida, se genera un esquema normalizado que actúa como la capa Silver, almacenándose en formato Parquet dentro de HDFS. Tal y como se observa en la parte superior de la Ilustración 2, este modelo en estrella tiene como núcleo una tabla central de hechos municipales que se cruza, mediante el código del municipio y el año, con diversas dimensiones temáticas, abarcando información demográfica, económica, temporal, de luminosidad, tejido empresarial, migraciones, consumo de energía y características propias del municipio.




Ilustración 3- Ejemplo de consulta con PowerBI y su conexion automatica

La transición hacia la zona Gold representa la frontera entre el procesamiento distribuido y la explotación analítica final para los distintos casos de uso. A partir del modelo en estrella normalizado de la capa Silver, se establecen distintas vías de explotación.

Por un lado, este modelo en estrella se expone de forma nativa mediante conectores ODBC hacia MariaDB para ser consumido por Power BI, facilitando la creación de cuadros de mando operativos que permiten cruzar dinámicamente las métricas. Su utilidad se puede ver en la Ilustración 3 donde se da un ejemplo de cómo se vería si se hiciese una consulta individual por hecho y dimensión, manteniendo automáticamente la lógica. Además, este mismo esquema relacional se utiliza de manera directa para alimentar los algoritmos de Machine Learning enfocados en la segmentación, como el clustering con K-Means. Sin embargo, para los algoritmos orientados a la regresión predictiva, como Random Forest o XGBoost, se requiere una estructura tabular plana. Por ello, se implementa un proceso de desnormalización masiva que da lugar a la capa Gold, visible en la parte inferior de la como la tabla aplanada `fact_master_gold`. Esta estructura rompe la jerarquía de las dimensiones y consolida sus 77 métricas en una única fila por municipio y año, agrupando de forma directa campos como la renta media, la población total, la radiancia lumínica nocturna y las estaciones de transporte, resultando una transformación indispensable para el entrenamiento de los modelos de regresión.

Cuadro de Mando: Operativo

Hemos diseñado este primer cuadro de mandos con un enfoque fundamentalmente analítico y operativo, dirigido de manera específica a perfiles de analistas de datos y operadores locales que requieren realizar diagnósticos continuos sobre el terreno. Su naturaleza analítica me permite habilitar una exploración profunda y el cruce empírico de múltiples dimensiones sociodemográficas y de infraestructura. Al mismo tiempo, cumple una función inapreciable, aunque las fuentes como los censos del INE, las descargas de Overpass o el procesamiento de imágenes satelitales no generan registros de alta frecuencia diaria, el procesamiento y la comparativa mensual de sus deltas me permite exponer la radiografía más actual y precisa posible del territorio. De este modo, la herramienta opera alertando sobre estados latentes y anomalías estructurales.




Ilustración 4- Mockup de Vista Territorial (Datos y estructura ficticia)

Delta de Radiancia Nocturna (Pulso Económico): Para capturar el pulso económico real de cada zona de manera puramente empírica, este indicador calcula la variación porcentual de la luz nocturna emitida respecto al mismo periodo del año anterior. Su utilidad es fundamental, ya que una caída drástica en la luminosidad revela apagones industriales o contracciones productivas mucho antes de que impacten en los registros oficiales, mientras que los incrementos sugieren expansiones empresariales.

Variación Neta de Población: Como base fundamental del análisis territorial, este indicador evalúa el crecimiento o declive demográfico estricto del municipio. Se calcula comparando datos del INE, obteniendo así el porcentaje de cambio real en el número de habitantes a lo largo del periodo de estudio. Esta métrica es esencial para trazar la curva de supervivencia de la localidad, permitiendo visualizar gráficamente si el municipio se encuentra en una fase de estancamiento, en un proceso de vaciado acelerado o experimentando un auge poblacional.

Saldo Migratorio Neto: Para comprender los motivos subyacentes detrás de la curva de población, se ha aislado este indicador que cuantifica dinámicamente el flujo de entradas frente a las salidas de residentes en cada municipio. Su inclusión es estratégica, ya que permite al analista descifrar de inmediato si un crecimiento poblacional aparente responde

simplemente a una inercia temporal o si, por el contrario, el territorio analizado está operando como un motor real de atracción capaz de retener capital humano.

Score de Conectividad Terrestre: Para contextualizar el riesgo de despoblación asociado a las infraestructuras, hemos desarrollado este cálculo espacial que evalúa el grado de aislamiento físico. Se genera ejecutando un análisis sobre la red, midiendo la distancia exacta desde el centroide geográfico de cada municipio hasta los nodos logísticos operativos y evaluando la densidad de dicha red en su área de influencia. Comprender este nivel de conexión facilita confirmar si la fuga de habitantes de una comunidad está siendo precipitada directamente por su desconexión de los grandes ejes.

Delta del Tejido Empresarial Logístico: Hemos incorporado este indicador estadístico diseñado para cuantificar la vitalidad comercial de transporte. Se calcula monitorizando la fluctuación temporal en el volumen de empresas de transporte y operaciones logísticas radicadas en el territorio, evaluando la proporción mensual de altas frente a las bajas corporativas en nuestra base de datos. Este KPI opera como un excelente indicador económico adelantado.

Todos estos indicadores cobran sentido práctico a través de un diseño de interfaz interactivo, cuyo epicentro visual y funcional es un mapa cartográfico de segmentación. Para garantizar una navegación fluida, he implementado una barra de búsqueda con un sistema de doble granularidad que permite al operador introducir tanto el nombre de una provincia como el de un municipio o su respectivo código LAU_ID. Si la consulta se realiza a nivel provincial, el mapa ajusta su encuadre panorámico, visualiza el conjunto de poblaciones que la componen y recalcula de forma agregada todos los KPIs para proyectar fielmente la media de la región. Por el contrario, al buscar un municipio específico, el visor realiza un drill-down hasta esa localidad, transformando por completo el cuadro de mandos para reflejar su estado individual y desplegando gráficos de series temporales que ilustran el comportamiento histórico y la tendencia temporal exacta de cada una de sus variables.

Cuadro de Mando Táctico- Panel Predictivo y de Riesgo

A diferencia del visor cartográfico operativo, hemos diseñado este segundo cuadro de mandos con una naturaleza puramente estratégica y directiva. Está pensado para perfiles ejecutivos, alcaldes, planificadores regionales o inversores que no buscan explorar el histórico detallado de un dato, sino que requieren comprender el panorama futuro y la categorización estructural de las zonas para asignar presupuestos o diseñar políticas frente al reto demográfico. Por ello, su interfaz de usuario prescinde de los mapas de exploración profunda y, en su lugar, prioriza visualizaciones orientadas a la toma de decisiones rápidas e informadas, empleando gráficos de radar para ilustrar la identidad del municipio y medidores de tendencia para las proyecciones a largo plazo. Al conectarse directamente a nuestra Capa Gold (el Dataframe Maestro), este panel no calcula medias al vuelo, sino que consume los resultados ya procesados por nuestros algoritmos de Machine Learning, presentando las conclusiones de nuestros motores de regresión y nuestro clasificador a través de métricas ejecutivas claras.




Ilustración 5- Mockup de Vista Predictiva (Datos y estructura ficticia)

- **Proyección Demográfica a 5 Años:** Este indicador constituye la métrica estrella del panel predictivo, ofreciendo el porcentaje esperado de crecimiento a medio plazo. Su inmenso valor estratégico radica en que en lugar de asumir que un pueblo grande seguirá siendo grande simplemente por su historia, el algoritmo evalúa su vitalidad actual, proporcionando a los directivos una alerta temprana y real sobre el riesgo de vaciado inminente o la necesidad de prever infraestructuras ante un auge.
- **Previsión del Pulso Económico (Motor VIIRS):** Acompañando a la proyección poblacional, hemos integrado un segundo indicador continuo que predice la vitalidad comercial y productiva del territorio a 5 años vista. Este KPI se alimenta de las inferencias de nuestro segundo modelo de regresión (Random Forest Luz), diseñado específicamente para proyectar la variación futura de la radiancia nocturna.
- **Perfil de Desarrollo Estratégico:** Más allá de las proyecciones numéricas continuas, hemos incorporado este KPI categórico que etiqueta la identidad estructural y vocación económica del municipio analizado.
- **Driver Predictivo Crítico:** Para garantizar que las proyecciones de la inteligencia artificial sean interpretables y verdaderamente accionables, este indicador cualitativo extrae y muestra en pantalla la variable específica que más está condicionando el futuro de la localidad

Por último, habría que destacar el Simulador Interactivo. Hemos integrado en el panel un simulador dinámico alimentado en tiempo real por los modelos de regresión. Esta herramienta interactiva permite a los usuarios modificar manualmente variables independientes claves del municipio directamente desde la interfaz. Por ejemplo, simulando mediante un deslizador los efectos del Score de Conectividad. Al alterar estos parámetros, el backend procesa la nueva matriz de datos a través de los algoritmos serializados y recalcula instantáneamente los nuevos escenarios predictivos para la demografía y la economía. Esta funcionalidad convierte a GeoLúmica en una herramienta que permite a la administración preevaluar empíricamente el retorno de inversión demográfico y social de sus políticas antes de ejecutar un presupuesto real.