



Universidad Europea

UNIVERSIDAD EUROPEA DE MADRID

Big Data II

Geolumica: Reporte de Machine Learning (ML)



G E O L U M I C A
C I T I E S F U T U R E

Integrantes:

Martin Eduardo Otero Di Lorenzo

Iker Arredondo Molina

Fernando Sánchez Rodríguez-Pascual

Introducción

El análisis de la evolución demográfica y económica de los municipios españoles es un desafío multidimensional. Fenómenos complejos como la despoblación rural, uno de nuestros blancos principales, la expansión de los alrededores metropolitanos o el desarrollo de nuevos nodos logísticos no pueden explicarse mediante una única variable. El proyecto GeoLumica nace con el propósito de decodificar esta realidad territorial integrando fuentes de datos masivas y heterogéneas desde la intensidad de luz nocturna satelital (VIIRS), hasta por indicadores de conectividad (OSM) y demografía oficial (INE).

El uso de técnicas tradicionales de estadística descriptiva resulta insuficiente para capturar las relaciones ocultas y no lineales entre estas tantas de variables a lo largo del tiempo. Por ello, la aplicación de modelos de Aprendizaje Automático (ML) en GeoLumica no es solo una elección metodológica, sino una necesidad analítica. El aprendizaje automático nos permite transformar millones de registros en bruto en conocimiento accionable para la toma de decisiones estratégicas o la inversión pública.

Para abordar este reto, la arquitectura de Machine Learning de GeoLumica se ha diseñado bajo un enfoque dual y complementario:

1. **Diagnóstico del Presente (Aprendizaje No Supervisado):** En una primera fase, se aplican algoritmos de Clustering para realizar una segmentación inteligente del territorio. El objetivo es identificar perfiles municipales ocultos en los datos, agrupando los más de 8.000 municipios en categorías reales (como "Motores Económicos" o "Núcleos Rurales Estancados") sin sesgos previos.
2. **Proyección del Futuro (Aprendizaje Supervisado):** Orientado a la proyección temporal, la predicción de variaciones demográficas y la simulación de escenarios futuros.

En los siguientes apartados se detalla el ciclo de vida completo de los modelos, desde la ingesta y limpieza del dato, hasta la ingeniería de características (Feature Engineering), el entrenamiento de los algoritmos y la evaluación de sus métricas de rendimiento.

Aprendizaje No Supervisado: Segmentación Territorial (Clustering)

2.1 Entrada de datos

El objetivo de esta fase es descubrir la estructura oculta de los 8.131 municipios españoles, agrupándolos según su similitud multidimensional sin imponer etiquetas predefinidas. Para lograrlo, se ha diseñado un *pipeline* específico de tratamiento de datos y modelado.

Para que la clasificación de los municipios sea realmente profunda, el modelo se nutre de ocho dimensiones de información distintas. Esto nos permite cruzar el rastro físico con datos oficiales de economía y población. Un reto importante en la gestión de estos datos es que los nombres de los municipios suelen presentar variaciones, algunos cambian con el tiempo, otros se escriben de forma distinta según la fuente o utilizan nombres cooficiales. Para evitar cualquier error de duplicidad o pérdida de información, el sistema ignora los nombres de los pueblos como identificador y utiliza en su lugar el código oficial de municipio (LAU_ID). Esto garantiza que, aunque un nombre cambie, los datos siempre se asignen al lugar correcto.

Además, este diseño multidimensional hace que el modelo sea muy resistente a los huecos de información. Si a un municipio le falta un dato específico, el algoritmo no lo descarta. En su lugar, es capaz de situarlo y clasificarlo utilizando el resto de las dimensiones que sí están disponibles. A continuación, se detalla el nivel de cobertura logrado en cada dimensión tras el proceso de limpieza y unión de datos:

Dimensión Analítica	Cobertura	Estado y Observaciones
Luces (VIIRS)	100.00%	✓ Cobertura total de los 8.131 municipios.
Migraciones	100.00%	✓ Información de flujos de población.
Conectividad	100.00%	✓ Datos de conectividad en todo el territorio.
Transporte (OSM)	100.00%	✓ Distancias a infraestructuras clave completas.
Empresas Logística	99.99%	⚠ Solo falta 1 municipio (<i>Viacamp y Litera</i>).
Renta / PIB	99.90%	⚠ Faltan 8 municipios (<i>Ej: Benitagla, Carrascalejo</i>).
Demografía (INE)	99.78%	⚠ Faltan 18 municipios (<i>Ej: Cabanes, Mieres</i>).
Consumo Viviendas	38.61%	⚠ Faltan 4.992 municipios por limitación de la fuente. (Solo tiene de municipios importantes).

2.2 Feature Engirneering

La ingeniería de características es el paso más crítico para que un modelo de Clustering funcione correctamente, y responde a dos necesidades fundamentales. La primera es estructural, algoritmos exigen que cada sujeto de estudio esté representado por una única observación en la matriz de datos. Dado que nuestras fuentes originales contienen múltiples registros por, ha sido estrictamente necesario agrupar y colapsar toda esta información para obtener exactamente una fila por municipio.

La segunda necesidad es matemática. El modelo de K-means, por ejemplo, calcula la similitud basándose en la distancia entre los valores. Si utilizáramos los datos en bruto, municipios gigantes como Madrid aparecerían como anomalías que succionan al resto de grupos hacia ellos, ocultando la realidad de los pueblos más pequeños. Para evitar este sesgo, hemos transformado los volúmenes absolutos en ratios y porcentajes, permitiendo que el algoritmo compare a una aldea y a una capital en igualdad de condiciones.

En la dimensión demográfica y migratoria, extrajimos la población actual como ancla de tamaño, pero el peso analítico recae en las variables dinámicas. Calculamos la tasa de variación histórica para medir el crecimiento o vaciamiento real. Además, incluimos el ratio de masculinidad (hombres sobre mujeres), una métrica donde un valor inusualmente alto señala núcleos en declive profundo por la emigración de mujeres jóvenes. Finalmente, transformamos los flujos migratorios brutos en una tasa migratoria %, revelando la atracción de un municipio independientemente de sus habitantes.

Para la dimensión de luminosidad satelital (VIIRS), además de aislar la radiancia reciente (`luz_absoluta_actual`), calculamos la evolución a largo plazo (`delta_luz_pct`). Un crecimiento lumínico alto sin crecimiento poblacional suele delatar la creación de polígonos industriales. También, calculamos la desviación estándar mensual de la luz (`luz_volatilidad_std`), lo que permite al modelo detectar la estacionalidad de las zonas turísticas que brillan intensamente en verano/invierno pero se apagan el resto del año.

En la dimensión económica y de renta, utilizamos los datos de la Agencia Tributaria para establecer el nivel de riqueza reciente con el pib histórico y actual.. Cabe destacar que a los escasos municipios protegidos por el Secreto Estadístico se les imputó la media económica de su provincia.

Finalmente, en la dimensión de conectividad, infraestructura y logística, combinamos fuentes de OpenStreetMap y registros automotores. La variable de empresas de transporte % detecta los nodos logísticos periféricos. La infraestructura física se mide mediante el aislamiento (distancia media a una estacion) y la concentración metropolitana (densidad en km). Por último, la motorización se evalúa con el `Indice_Conectividad` general y el `Pct_Vehiculos_Muni_vs_Prov`, una métrica excelente para que el modelo identifique a las "capitales de facto" que absorben la movilidad de su provincia.

A continuación, se presenta la matriz final inyectada en el algoritmo (compuesta por 16 variables sobre más de 8.000 municipios):

Variable Final	Dimensión	Descripción / Cálculo
pob_absoluta_actual	Demografía	Población total actual
delta_pob_pct	Demografía	% Cambio poblacional
ratio_masculinidad	Demografía	Hombres / Mujeres
tasa_migratoria_pct	Demografía	Saldo migratorio / Población
luz_absoluta_actual	Luces (VIIRS)	Brillo nocturno actual
delta_luz_pct	Luces (VIIRS)	% Cambio en brillo nocturno
luz_volatilidad_std	Luces (VIIRS)	Volatilidad mensual (estacionalidad)
pib_absoluto_actual	Renta/PIB	Riqueza total actual
pib_media_historica	Renta/PIB	PIB promedio histórico
pib_volatilidad_std	Renta/PIB	Fluctuación del PIB (resiliencia)
empresas_transporte_actual	Logística	Nº empresas de transporte
delta_empresas_transporte_pct	Logística	% Cambio empresas logísticas
stations_density_km2	OSM	Estaciones de tren / km ²
mean_distance_km_to_station	OSM	Distancia media a estación (km)
Indice_Conectividad	Movilidad	Índice de motorización
Pct_Vehiculos_Muni_vs_Prov	Movilidad	% Vehículos sobre el total provincial

2.3 PCA y Division

A pesar de haber convertido los valores absolutos en ratios y densidades durante la fase anterior, las grandes metrópolis españolas poseen un comportamiento socioeconómico tan extremo y único que siguen generando un fuerte efecto en el espacio de datos. Para evitar que estas anomalías distorsionaran la agrupación del resto del país, se implementó un filtro de separación previo al modelado.

El sistema aisló 153 gigantes urbanos, reservándolos para un análisis independiente. Esto nos dejó con una matriz depurada de 7.978 municipios, permitiendo que el algoritmo se concentre con precisión en el verdadero objetivo de GeoLumica, encontrar los patrones ocultos de la España rural, las ciudades medianas y los territorios en riesgo de despoblación.

Con la matriz rural estandarizada, nos enfrentamos al problema conocido como “Dimensionality Curse”, donde al trabajar con 16 dimensiones hace que el cálculo de distancias matemáticas para el algoritmo K-Means sea ineficiente, especialmente porque muchas variables originales presentan alta correlación.

Para resolverlo, aplicamos el Análisis de Componentes Principales (PCA), una técnica que comprime el espacio de datos creando nuevas dimensiones ortogonales que resumen

la esencia de los municipios de forma compacta. Para determinar cuántos componentes debían conservarse sin perder calidad analítica, se generó la Ilustración 1.




Ilustración 1- Scree Plot para PCA

Como demuestra la gráfica, se fijó un umbral de calidad cercano al 90% de información retenida (representado por la línea discontinua roja). La curva interseca este umbral de manera casi exacta en el Componente 10 (89.49%), el numero optimo sin retener ruido.

2.4 K-Means - Optimizacion e Interpretacion

Con la matriz estabilizada y reducida a 10 componentes principales, se procedió a la fase de entrenamiento utilizando el algoritmo K-Means. Dado que este modelo requiere definir a priori el número exacto de grupos (K) en los que se dividirá el territorio, la selección se delegó a una evaluación puramente algorítmica, iterando modelos desde K=3 hasta K=10. Para determinar el punto óptimo de partición y garantizar una segmentación sin sesgos humanos, se aplicaron conjuntamente el Método del Codo (evaluando la Inercia) y el Coeficiente de Silueta (Silhouette Score).




Ilustración 2-Optimizacion del modelo

El análisis cruzado de ambas métricas arrojó una conclusión matemática clara. Como se puede observar en la gráfica y en los datos resultantes, el Coeficiente de Silueta alcanza su máximo absoluto exactamente en la partición de $K=5$ (0.1947). Al mismo tiempo, esta decisión se ve respaldada por la curva de Inercia, ya que justo en el salto hacia $K=5$ se registra la caída marginal más brusca de todo el experimento (un descenso de más de 6.434 puntos respecto a $K=4$). A partir de ese punto, el rendimiento general decae, indicando que forzar más agrupaciones solo conseguiría fracturar artificialmente territorios que comparten un mismo perfil.

- **Clúster Rural 5:** 1 - Despoblación Grave (Pueblos en riesgo crítico)
- **Clúster Rural 1:** 2 - Pérdida Moderada (Pueblos que se vacían lentamente)
- **Clúster Rural 3:** 3 - Población Estable (Pueblos medianos sin grandes cambios)
- **Clúster Rural 0:** 4 - Crecimiento Leve (Pueblos que atraen nuevos vecinos)
- **Clúster Rural 2:** 5 - Fuerte Crecimiento (Zonas residenciales y turísticas)
- **0 - Grandes Urbes:** 6 - Grandes Ciudades (Capitales y grandes núcleos)
- **Clúster Rural 4:** 7 - Enormes Centros Logísticos (Zonas de gran industria y transporte)

Una vez el algoritmo K-Means finalizó la segmentación sobre la matriz rural reducida, el *pipeline* ejecutó un paso de reintegración algorítmica. El grupo de los 153 gigantes urbanos (aislados en la fase de preprocesamiento para evitar el "efecto gravedad") fue reincorporado al conjunto de datos maestro, asignándoles su propia categoría inmutable. El resultado final de este modelo híbrido es una radiografía completa del territorio nacional dividida en 7 perfiles estructurales (1 perfil metropolitano y 6 perfiles rurales/intermedios), que encapsulan toda la diversidad demográfica y económica del país.




Ilustración 3- Gráfica de los clusters en un mapa de España en 2D

Al proyectar esta clasificación sobre el mapa cartográfico de España, el resultado visual resulta altamente intuitivo y, a primera vista, guarda una fuerte similitud con los clásicos mapas de densidad poblacional publicados por fuentes oficiales, donde la costa, los archipiélagos y el área metropolitana de Madrid destacan frente al vacío del interior peninsular. Sin embargo, es vital subrayar que esta similitud cartográfica es, en parte, un espejismo de la representación en dos dimensiones (2D).

Mientras que los mapas tradicionales colorean los municipios basándose en una única variable, habitantes por kilómetro cuadrado, nuestro mapa representa fronteras multidimensionales. Dos municipios que en el mapa comparten el mismo color no solo tienen tamaños parecidos, sino que comparten el mismo patrón de migración, ratios similares de masculinidad, la misma volatilidad en su luz nocturna, distancias equivalentes a hospitales e infraestructuras, y tendencias logísticas análogas. El mapa es una simplificación visual plana de un problema matemático de alta complejidad que el modelo ha resuelto operando en un espacio de 10 dimensiones simultáneas.

A continuación, se presenta la tabla resumen extraída directamente del motor del modelo:

Métrica Analítica	Grandes Urbes	C0	C1	C2	C3	C4	C5
Total Municipios	153	1,036	3,601	110	348	34	2,849
Población Media	92,237	4,440	706	19,538	22218	1,162	117
Var. Poblacional	+24.3%	+72.1%	-19.9%	+42.9%	+25.6%	+42.4%	-27.7%
Var. Luz (VIIRS)	+37.4%	+47.8%	+163.9%	+52.4%	+54.9%	+77.8%	+246.6%
PIB Medio (€)	12,658	12,824	10,509	12,814	10,677	11,876	14,629
Var. Logística	-12.4%	-6.3%	0.0%	-15.4%	-12.9%	+3450%	0.0%
Dist. Estación	0.0 km	0.0 km	0.0 km	0.0 km	0.0 km	0.0 km	11.5 km
Ratio Masculinidad	0.95	1.02	1.06	0.96	0.98	1.04	1.26

Al analizar los promedios, el dato más disruptivo es el extraordinario crecimiento del +3450% en empresas de transporte del Clúster 4. Este fenómeno identifica pequeños municipios (apenas 1.162 habitantes de media) que se han transformado en polígonos logísticos. Al observar su distribución espacial en el mapa, vemos que no se ubican al azar: forman un claro anillo alrededor de las Grandes Urbes como Madrid. El algoritmo ha demostrado visual y matemáticamente cómo la industria abandona el caro suelo del centro de Madrid o Barcelona para irse a los alrededores. Como contraste perfecto en el extremo opuesto, el modelo también aísla la despoblación estructural en el Clúster 5, identificando el núcleo duro de la España Vacía a través de su aislamiento físico (11.5 km de media a una estación) y su severa caída demográfica (-27.7%).

2.5 Metodos Supervisados (Con etiquetas del K-Means)

Antes de iniciar la fase de predicción, el pipeline de datos incorporó una última capa de ingeniería de características puramente espacial. La dinámica de un territorio rara vez es un fenómeno aislado; en geografía humana existe una fuerte autocorrelación con los vecinos donde el destino de un municipio está ligado al de su entorno. Para que la Inteligencia Artificial pudiera capturar este efecto de arrastre, se calcularon variables de rezago espacial (Spatial Lag). Estas nuevas métricas cuantifican el crecimiento demográfico y lumínico de los pueblos colindantes, permitiendo al modelo comprender si un núcleo crece por mérito de sus propias infraestructuras o si simplemente está siendo empujado por la onda expansiva de una capital vecina. Además, se usó como variable predictora la etiqueta de segmentación (Perfil Final) descubierta en la fase anterior, logrando que el modelo supervisado herede la inteligencia territorial del K-Means.

La fase de modelado utilizó una división 80/20 para el entrenamiento y test de los algoritmos. Dada la altísima dimensionalidad se descartó de inicio el uso de regresiones lineales tradicionales. Concretamente se implementaron modelos de ensamble como Random Forest y XGBoost por su gran capacidad para gestionar relaciones no lineales complejas. Finalmente, para maximizar la capacidad predictiva se hizo un Randomized Search CV, iterando hasta encontrar los hiperparámetros más robustos para el modelo.

Tras la búsqueda estocástica de hiperparámetros, obtuve las configuraciones óptimas para ambas arquitecturas. Para el Random Forest, el modelo alcanzó su mejor versión con 200 estimadores, un mínimo de 5 muestras para dividir nodos, sin límite de profundidad máxima y balanceando los pesos de las clases. Por su parte, el modelo Gradient Boosting (XGBoost) requirió una configuración más calibrada para evitar el sobreajuste: 100 estimadores, una profundidad máxima acotada a 3 , un learning_rate de 0.1 y un submuestreo del 80% de los datos por árbol.

Para determinar cuál de los dos motores impulsaría las proyecciones finales de GeoLúmica, evalué ambos algoritmos sobre el 20% de los datos ocultos. La siguiente tabla compara el rendimiento de ambos modelos métrica a métrica (F1-Score):

Perfil Territorial (Clúster a predecir)	F1-Score (Random Forest)	F1-Score (XGBoost)
1 - Despoblación Grave	0.93	0.95
2 - Pérdida Moderada	0.95	0.96
3 - Población Estable	0.93	0.93
4 - Crecimiento Leve	0.88	0.90
5 - Fuerte Crecimiento	0.94	0.96
6 - Grandes Ciudades	0.98	1.00
7 - Centros Logísticos	1.00	1.00
Precisión Global (Accuracy)	94%	 95%

Para entender exactamente dónde se equivocaba ese 5% restante del modelo XGBoost, generé y analicé su matriz de confusión sobre las predicciones del test.




Ilustración 4-Matriz de Confusion de XGBoost

Como se observa en la matriz, la inmensa mayoría de las predicciones se concentran en la diagonal principal, lo que confirma visualmente el altísimo nivel de acierto. Lo más interesante a nivel analítico son los errores del modelo, ya que tienen sentido demográfico y geográfico. El modelo no comete errores graves (es decir, no confunde un pueblo vaciado con una gran ciudad). Las pocas desviaciones ocurren en fronteras difusas.




Ilustración 5- Feature Importance Top 15- XGBoost

Finalmente, para verificar que las predicciones del algoritmo están fundamentadas, extraje el peso de las variables (*Feature Importance*) del XGBoost. Los resultados confirman que no es un modelo vago o unidimensional. Aunque la lógica dicta que los pilares principales sean la riqueza reciente y el tamaño base, el algoritmo distribuye estratégicamente el resto de su capacidad de decisión entre otros indicadores dinámicos.

Aprendizaje Supervisado: Regresión y Simulación a 5 Años

La fase de regresión supervisada tiene como objetivo construir el motor predictivo de GeoLúmica: un simulador dinámico capaz de proyectar el futuro a medio plazo.

Para alimentar el Dashboard interactivo de la herramienta, se abandonó la aproximación clásica de predecir el año inmediatamente posterior. En su lugar, se rediseñó la arquitectura de datos para proyectar un horizonte a 5 años vista. Este enfoque permite a los tomadores de decisiones evaluar el impacto real a largo plazo de las políticas públicas o inversiones logísticas.

3.1. Corrección Temporal y Prevención de Fuga de Datos (Data Leakage)

Durante la integración inicial de las fuentes, se detectó un desafío estructural que amenazaba la integridad del modelo predictivo, la disonancia de granularidad temporal entre el censo (anual) y la luminosidad satelital VIIRS (mensual). Un cruce directo provocaba una multiplicación artificial de los registros, generando 12 filas por municipio y año. Esto inducía un grave efecto de fuga de datos (*Data Leakage*), permitiendo que el algoritmo se aprendiera de memoria la población de un mes a otro, inflando artificialmente las métricas de acierto.

Para solventarlo, se implementó una agregación longitudinal de la matriz satelital, colapsando los 12 meses en métricas anuales de intensidad media y desviación estándar (volatilidad turística). Esta compresión garantizó la regla de oro del modelado: un registro único por municipio y año. Se hizo lo mismo para el resto de variables con distintas granularidades.

3.2. Ingeniería de Características Relativa y Filtro Rural

En el modelado predictivo, los volúmenes absolutos generan un fuerte sesgo hacia los polos metropolitanos. Para evitar que el algoritmo discriminara a la España Vacía, se inyectó el Feature Engineering diseñado en la fase de clasificación, pero adaptado a series temporales. Variables crudas fueron sustituidas por métricas relativas que evalúan el "magnetismo" real del territorio:

- **Tasa Migratoria Relativa:** Saldo migratorio normalizado por cada 1.000 habitantes.
- **Ratio de Masculinidad:** Indicador temprano de la migración rural femenina.
- **Tasa de Empresas Logísticas:** Densidad industrial de transporte per cápita.

Adicionalmente, se aplicó una estricta segmentación de negocio. Dado que las dinámicas de crecimiento de una ciudad de 3 millones de habitantes difieren radicalmente de las de un municipio rural, se excluyeron del entrenamiento predictivo a las grandes urbes (> 50.000 habitantes). Al aislar la matriz rural e intermedia, el algoritmo se especializó exclusivamente en las reglas de supervivencia y declive de la España menos poblada.

3.3. El Salto Temporal y la "Cura del Espejismo de la Inercia"

Para transformar el dataset en una máquina de simulación futura, se aplicó una técnica de *Time-Shifting*. Mediante el desplazamiento del vector objetivo en 5 años (Año Base =

Año - 5), se logró alinear en una misma matriz las características independientes de un año histórico X con su desenlace real en el año $X+5$.

Durante las primeras iteraciones de entrenamiento previendo la "Población Total", el modelo alcanzó un R^2 superior a 0.99. Sin embargo, el análisis de explicabilidad reveló que este resultado era un "Espejismo de la Inercia", el algoritmo simplemente copiaba la población del año anterior, ignorando las variables socioeconómicas. Para curar esta autocorrelación extrema, se transformó la variable objetivo (Target). En lugar de predecir el volumen total, se forzó al algoritmo a predecir el Crecimiento Neto a 5 años (Variación poblacional). Este cambio exigió al modelo comprender de forma genuina el impacto de la conectividad, la renta y la industria para determinar si un municipio ganaría o perdería habitantes.

3.4. Entrenamiento Dual y Optimización (GridSearch)

La arquitectura predictiva se bifurcó en dos motores paralelos utilizando el algoritmo Random Forest Regressor, evaluados mediante una división temporal (datos pre-2017 para entrenamiento; datos post-2017 para poder tener una validación oculta).

1. **Motor Demográfico:** Proyecta la variación neta de habitantes.
2. **Motor Económico (VIIRS):** Proyecta la variación de la luz nocturna, actuando como un oráculo indirecto de la futura actividad comercial e industrial del municipio.

Para maximizar el rendimiento sin caer en el sobreajuste computacional, se empleó una búsqueda estocástica de hiperparámetros (RandomizedSearchCV). La configuración óptima para el modelo de Población convergió en 100 estimadores, con una división mínima de 5 muestras y 4 hojas mínimas (nodos terminales robustos). Mientras que el modelo de Luminosidad, dada su menor aleatoriedad, optimizó en 100 estimadores, limitando su profundidad máxima a 20 niveles y exigiendo 10 muestras mínimas por división.

3.5. Resultados, Métricas y Explicabilidad (Feature Importance)

Los resultados sobre el conjunto de prueba (el futuro no visto por el modelo) validaron rotundamente la arquitectura.

El Modelo de Luminosidad Económica Alcanzó un R^2 de 0.9739. Dada la naturaleza física de la infraestructura lumínica (farolas, naves logísticas), el modelo es capaz de proyectar la actividad industrial a medio plazo con una precisión quirúrgica.

Mientras tanto, el modelo Demográfico a 5 años (Evolución y Crecimiento Neto): El rendimiento definitivo de este modelo debe analizarse comprendiendo la evolución metodológica de su variable objetivo. En las iteraciones previas del proyecto, cuando se instruyó al algoritmo para predecir la "Población Total" absoluta a 5 años, el modelo arrojaba un coeficiente de determinación (R^2) engañosamente perfecto de 0.9975 y un Error Absoluto Medio (MAE) de 108.47 habitantes. Como se diagnosticó en la fase de explicabilidad, esto era un Espejismo de Inercia.

Al transformar la arquitectura para predecir la variación exacta (el crecimiento o decrecimiento neto), se eliminó esta ventaja inercial. En este nuevo escenario de exigencia real, el modelo alcanzó un R^2 de 0.5262. Lejos de ser un empeoramiento, es un rendimiento excelente en el ámbito de la demografía y las ciencias sociales; demuestra que el algoritmo es capaz de explicar más de la mitad de la altísima imprevisibilidad de la migración humana. Desde la perspectiva de negocio, con este cambio la precisión real mejoró: el Error Absoluto Medio (MAE) se redujo a 99.65 habitantes. Esto indica que el simulador interactivo de GeoLúmica es capaz de prever el destino de un municipio de la España Vaciada a un lustro vista equivocándose, en promedio, en menos de 100 personas.

Para verificar la reflexión del modelo demográfico, se extrajo la Importancia de Variables (*Feature Importance*):




Ilustración 6 - Feature Importance del Motor Predictivo Demográfico (Random Forest)

Tras neutralizar la inercia del año anterior (que ahora supone solo ~25% del peso predictivo), el 75% de las decisiones matemáticas recaen sobre variables territoriales accionables. Destacan como motores principales la **Tasa Migratoria** de atracción, el nivel de **Renta Media** y la "actividad en la sombra" detectada por los satélites **VIIRS**, validando la hipótesis central del proyecto GeoLúmica: la demografía del futuro está escrita en las luces, conectividad y la economía del presente.

3.6. Despliegue en Producción

Por último, los algorítmicos optimizados fueron exportados mediante serialización binaria (.pkl). Al interactuar con el Dashboard, los parámetros modificados por el usuario alimentarían instantáneamente estos archivos subyacentes, devolviendo proyecciones dinámicas e interactivas sin necesidad de recalcular el aprendizaje del modelo.